

毕业设计中期检查报告

2211532 石家伊 信息安全

- 题目：**基于图粗化的社交网络分析系统的设计与实现
- 英文题目：**Design and Implementation of Social Network Analysis System Based on Graph Coarsening

一、选题描述

社交网络分析 (Social Network Analysis, SNA) 以社交关系为研究对象，将用户、组织、账号等实体抽象为图 (Graph) 中的节点，将关注、好友、转发、互动等关系抽象为边，从而研究个体与群体之间的结构特征、传播规律与演化机制。

在现实平台中，社交网络往往是规模巨大且结构复杂的，其节点数可能从几千到千万级，边数可能从数万到数十亿级不等，同时还伴随高度稀疏、长尾分布、强异质性与噪声边等特征。无论是传统图算法，如社区发现算法、谱方法等，还是近年来广泛使用的图表示学习/图神经网络 (GNN)，在如此超大规模的社交图上都容易遭遇计算复杂度高、内存与显存压力大、多维结构难以刻画等算力与存储上的瓶颈。

因此，本课题希望引入**图粗化 (Graph Coarsening, GC)** 技术，从系统设计角度解决“在可接受的计算成本内进行社交网络结构挖掘与分析”的工程问题。

图粗化是图缩减 (Graph Reduction) 家族的重要分支，其目标是在尽可能保持原图关键性质的前提下，将原图映射为规模更小的粗图 (coarse graph)。将图粗化用于社交网络分析系统可以带来许多优势：

- 提升下游任务效率与可扩展性：**通过减少节点与边数量，显著降低下游分析模块的时间与内存开销，减轻计算与存储压力，使系统具备处理更大规模社交图的能力。
- 保留并突出多尺度结构：**粗化后的超节点往往对应“局部密集结构”或“社区子结构”，有利于从宏观角度理解社交网络的圈层与组织形态。
- 增强鲁棒性与可解释性：**适当的粗化可在一定程度上抑制噪声边影响，并通过“超节点—原节点映射关系”提供解释路径。

本课题的研究目标：设计并实现一个基于图粗化的社交网络分析系统，以图训练、轻量级粗化算法为核心，将社交网络图压缩到多尺度表示，并支持对粗化前后结构与任务表现进行对比分析。

二、国内外研究进展综述

图缩减 (Graph Reduction) 旨在减少图规模或降低计算开销，同时尽可能保持原图的关键结构，如谱性质、社区结构或任务性能等。

Hashemi 等 (2024) 的图缩减综述系统梳理图缩减的相关方法，一方面将稀疏化、采样、粗化、凝聚/蒸馏、池化等方法放在同一框架下讨论；另一方面强调不同方法在“保持目标”与“适用任务”上的差异，从而为算法选型与系统落地提供参考：

- 图稀疏化 (Sparsification)：**主要减少边数，保持割 (cut) 或谱 (spectral) 性质。
- 图凝聚 (Condensation)：**生成小规模合成图以替代训练数据，同时保留 GNN 的性能。强调训练成本与效果权衡。
- 图粗化 (Coarsening)：**并非简单删除节点，而是将节点分组并合并为超级节点，将原始组间边聚合为超级边，构造多层次粗图。强调结构保持与可扩展分析。

- **图采样 (Sampling)**：选取节点/边子集近似原图统计，适合快速估计。
- **图池化 (Pooling)**：通常作为 GNN 内部模块，对图级任务进行层级聚合表示学习。

不同方向的目标函数与评价体系有所差异，如稀疏化更关注谱近似误差，凝聚更关注训练速度与最终精度，而粗化则更关注多尺度结构保持、映射关系质量与下游任务兼容性。

除综述外，本课题还阅读了若干与图缩减相关的研究工作，用于补充理解不同分支在目标与方法上的侧重点。

- **Gao 等 (2025)**：关注图凝聚/训练加速问题，强调在较低训练成本甚至免训练条件下构造更小的图数据以支持学习任务。该工作强化了本课题对“免训练/低训练更利于系统落地”的判断，也提示在处理类别/标签结构时需要关注分布保持与评价方式。
- **Ren 等 (2024)**：从层级划分结构出发提出 Hi-PART，强调用更明确的层级组织来表达多尺度信息。该思想与本课题“粗化生成多层图并用于多尺度社交网络分析”的系统目标一致，为后续在系统中组织粗化层级与可视化层级提供了参考。

三、已经开展的研究工作

3.1 实验路线设计

目前已完成题目确定与总体技术路线收敛：以图粗化作为系统的“压缩建模核心”，围绕数据接入、粗化复现、对比实验与系统实现组织工作。整体流程可以概括为：

社交网络数据集接入 → 数据分析与问题识别 → UGC 方法复现并形成可运行基线 → 将社交网络数据适配进粗化流程并做对比评估 → 以模块化方式整合为分析系统原型。

3.2 方法与数据集选取

3.2.1 文献调研与方法选型

在调研基础上，本课题选择近三年提出的 UGC (Universal Graph Coarsening) 作为粗化模块基础方法。UGC方法具有以下优势：

1. **开源可复现**：利于快速对照论文并形成稳定的工程实现。
2. **免训练优势**：后续工作可以围绕“免训练粗化的结构保持能力与系统增益”展开，避免在中期阶段过早陷入高成本训练与复杂调参。
3. **通用性导向**：目标更接近“为多种下游任务提供可用粗图”，适合作为系统核心算法模块。

3.2.2 社交网络数据集选取与来源

UGC 原实验数据集中缺少典型社交网络图，为体现课题的应用属性，我补充了三个社交网络数据集：Facebook、Twitter、TWeibo。

数据集来源为 PyTorch Geometric 的 [torch_geometric.datasets.AttributedGraphDataset](#)。数据集简介如下：

- **Facebook**：无向图；节点代表用户，边代表好友关系；属性由用户资料抽取；标签与自我中心网络相关。
- **Twitter**：有向图；节点代表用户，边代表关注关系；属性来自用户档案、推文关键词或标签等。
- **TWeibo**：有向图；节点代表微博用户，边代表关注关系；属性由用户资料中热门标签/关键词构成。

3.3 数据分析与问题发现

3.3.1 数据分析

在完成数据读取流程后，已对社交网络数据与 UGC 常用引文网络数据进行统计对比，形成表格化记录。统计指标包括：节点数 (Nodes)、边数 (Edges)、平均度 (Avg degree)、最大度 (Max degree)、特征维度 (Feature dim)、特征稀疏度 (feature sparsity)、标签张量形状 (label shape) 等。

得到的数据分析结果如下：

Dataset	Nodes	Edges	Avg degree	Max degree	Feature dim	feature sparsity	label shape
Cora	2,708	10,556	3.8981	168	1433	0.9873	[2708]
Citeseer	3,327	9,104	2.7364	99	3703	0.9915	[3327]
Facebook	4,039	88,234	21.8455	1043	1283	0.9936	[4039, 193]
Twitter	81,306	2,420,766	29.7735	3373	216839	0.9946	[81306, 4065]
TWeibo	2,320,895	50,655,143	21.8257	5188	1657	0.9956	[2320895,8]
Reddit	232,965	114,615,892	491.9876	21657	602	0.0	[232965]

3.3.2 发现问题

当前阶段的主要问题集中在以下三个方面：

(1) 标签与任务设定不兼容

这是目前遇到的最关键问题，多标签数据无法直接用于计算异质性因子 α 。UGC 模型中用于构造增强特征矩阵 F 的异质性因子 α 定义为：

$$\alpha = \text{不同类别之间的边数} / \text{总边数}$$

该定义要求每个节点具有单一类别标签，而选取的三个社交网络数据集，其中节点都具有多个标签。在这种情况下，无法直接使用原始标签计算 α ，导致模型无法按原论文方式融合节点特征与邻接信息。

在当前阶段实验中，暂时采用了只保留首个标签的方法，但该方法会造成标签信息的丢失，可能使得分类效果下降，因此，下一阶段计划尝试优化保留标签的策略，如选择主标签/最大权重标签，或通过规则将多标签映射为单类别，把社交数据改造成可以用 UGC 处理的单标签格式。

(2) 特征维度过高与数据规模过大

UGC 把特征和邻接向量拼起来，社交网络大图会很吃内存。UGC 会把每个节点的特征 X_i 和它的二值邻接向量 A_i 拼接成增广特征 F_i ，而且也提醒大图会导致向量很长，需要高效实现和稀疏张量方法。

选取的三个社交网络数据集中，Twitter 具有很高的特征维度，而 TWeibo 的节点数达到了百万级，这两个数据集都会导致内存不足。

后续实验中，对于具有高维特征的 Twitter 数据集，考虑先压缩原始特征，再做 UGC 的方法，对原始高维稀疏特征先降维；对于节点数非常多的 TWeibo 数据集，考虑分块批处理计算哈希，一次处理几万节点，每批单独算哈希最后进行拼接。

(3) UGC默认无向图

UGC 所提供的代码理论上可以读入有向边文件，因为 `edge_index` 只是边列表，代码不会因为是有向就立刻报错，但 UGC 的实现路径里大量操作默认是无向或对称邻接的思路，论文在 Background 里先定义：

- 图写成 $G(V, A, X)$
- A 是邻接矩阵， D 是度矩阵， $L = D - A$ 是 Laplacian
- 并且还特别声明

$$L_{ji} = L_{ij} \leq 0, \forall i \neq j$$

即 L 是对称的。

三个社交网络数据集中，除 Facebook 为无向图以外，Twitter 和 TWeibo 都是表示关注关系的有向图，后续实验中，会先保留有向图特征进行实验，并和进行对称化的方法进行对比，保留效果更好的策略。

四、已经取得的实验结果

4.1 UGC 复现结果

在复现实验中，采用记录参数如下：

- `model_type`: gcn
- `ratio`: 50（为了让实际压缩比例接近，在 Citeseer 上也测试了 ratio 为 30 的情况）
- `add_adj_to_node_features`: True

复现得到的部分结果如下表所示：

Dataset	异配因子 alpha	ratio	实际压缩比例	supernode	平均准确率	平均时间
Cora	0.19	50	48.63%	1391	0.8306	13.5029
Citeseer	0.26	30	40.06%	1994	0.7492	7.9755
		50	60.99%	1298	0.7222	16.0400

该结果与论文中作者给出的实验结果相符，说明所复现的实现具有较好的可信性。

从结果中可以看出，模型的压缩率与性能存在权衡，Citeseer 上 `ratio=50` 的实际压缩更高（60.99%），但平均准确率下降（0.7222），且时间上升（16.04）。这说明在系统落地中需要提供可调节的粗化强度，并记录效率/效果曲线。并且实际压缩比例与 ratio 不完全一致，实际压缩比例由数据与粗化策略共同决定，系统实现中应同时输出目标 ratio 与实际压缩统计，避免只记录输入参数而无法解释输出结果。

4.2 Facebook 数据集初步实验

为验证 UGC 在社交网络数据上的可运行性与参数敏感性，本阶段额外在 Facebook 数据集上完成了粗化与下游节点分类的初步实验。选择 Facebook 的原因在于其规模相对于 Twitter 和 TWeibo 更小，可在当前实验环境下稳定运行，无需处理内存不足等问题。

4.2.1 当前多标签处理策略

Facebook 标签张量形状为 `[N, 193]`，更接近多标签/成员关系指示矩阵。为兼容 UGC 复现实验中常用的单标签节点分类评价流程，本阶段采用了**只保留首个标签**的简化策略，将多列标签简化为单列标签用于训练与评估。

该策略的意义在于尽快获得“能跑通、可对照”的 baseline；其局限性是会损失原始标签语义，后续将以对照实验形式评估更合理的多标签处理方案。

4.2.2 alpha 梯度测试结果

由于超参数 alpha 在社交网络数据上缺少可直接沿用的确定取值，本阶段在 Facebook 数据集上对 alpha 做了梯度测试；固定目标压缩率 `ratio_target=50`，记录实际压缩比例（`ratio_actual`）、粗图超节点数（`supernode`）、平均准确率（`ave_acc`）与平均时间（`ave_time`），结果如下：

- `ratio_target` 均设置为 50

alpha	ratio_actual	supernode	ave_acc	ave_time
0	60.4357514236197	1598	0.3511	22.5071
0.05	51.6464471403813	1953	0.4771	25.6082
0.1	46.1995543451349	2173	0.5389	26.5205
0.2	38.7472146570933	2474	0.5377	26.6833
0.3	33.5479078979946	2684	0.5525	25.9587
0.5	27.0363951473137	2947	0.6205	28.4036
0.6	24.9566724436742	3031	0.6329	26.9075
0.7	23.050259965338	3108	0.6180	27.4758

通过该测试，可以得到以下结论：

1. **alpha 对压缩强度与准确率存在明显影响**：随着 alpha 参数增大，`ratio_actual` 逐步降低，而 `ave_acc` 整体呈上升趋势，说明在 Facebook 上适当增加结构信息的重要性有助于提升下游分类效果，但同时也使得压缩强度降低。
2. **facebook 上最优 α 在 0.5-0.6 区间**：这一区间内，模型的 `ave_acc` 最高，但实际压缩比例较低，如果想避免过度偏离压缩目标，也可以考虑 $\alpha=0.3$ ，但它们的 acc 会低一点。

五、未来进度计划

结合当前进展与剩余工作量，后续计划按阶段推进：

5.1 阶段一：解决内存瓶颈并跑通大图（预计 1 周）

- 采用可行策略跑通 Twitter 与 TWeibo 的粗化与下游流程，例如采用特征降维、子图/分块等方法，确保能稳定产出粗图与核心指标

5.2 阶段二：单标签化策略对照与 UGC 效果提升（预计 2 周）

- 系统化对比多种多标签到单标签的映射方案，如首标签、主标签/频次最大标签、规则映射等，并明确未标注节点处理方式
- 在社交网络数据集上开展参数与实现对比，包括 α 、ratio 与实际压缩比例、bin width 选择、是否对称化有向边等，形成对照表与曲线

5.3 阶段三：总结结果并撰写论文（预计 2 周）

- 完成实验结果的整理、图表绘制与对比分析
- 完成论文主体撰写与排版，补齐方法细节、实验设置、可复现性说明与参考文献
- 准备答辩材料与演示脚本

六、参考文献

1. Hashemi M, Gong S, Ni J, et al. A comprehensive survey on graph reduction: Sparsification, coarsening, and condensation[J]. arXiv preprint arXiv:2402.03358, 2024.
2. Gao X, Ye G, Chen T, et al. Rethinking and accelerating graph condensation: A training-free approach with class partition[C]//Proceedings of the ACM on Web Conference 2025. 2025: 4359-4373.
3. Ren Y, Zhang H, Fu L, et al. Hi-part: Going beyond graph pooling with hierarchical partition tree for graph-level representation learning[J]. ACM Transactions on Knowledge Discovery from Data, 2024, 18(4): 1-20.
4. Kataria M, Kumar S. Ugc: Universal graph coarsening[J]. Advances in Neural Information Processing Systems, 2024, 37: 63057-63081.