

各位老师好，我是信息安全班的石家伊。
我的毕业设计题目是“**基于图粗化的社交网络分析**”。

接下来我将从四个部分展开进行汇报，分别是研究问题及相关工作、已完成的解决方案、前期结果验证，以及后续计划。

1

首先我先来介绍一下我的选题情况

我的研究背景主要来自于社交网络分析面临的两个现实问题。

- 第一，**数据规模巨大**。随着社交网络规模不断增长，图数据的节点数、边数和特征维度都越来越大，传统方法在算力、内存和存储方面都面临很大压力。
- 第二，**结构刻画困难**。社交网络中的节点关系复杂，传统方法往往难以完整保留节点之间更深层的关联信息。

针对这些问题，我调研了图缩减领域的相关工作，主要包括**图稀疏化、图凝聚、图粗化和图采样**四类方法，这些方法各有特点，各有侧重。

其中，我重点选择了**图粗化**作为后续研究方向。原因在于，图粗化不是简单删边或者抽样，而是通过将相似节点合并成超级节点，在缩小图规模的同时，尽可能保留原图的重要结构信息，因此比较适合社交网络这种大规模、强结构性的图数据。

2

接下来，第二部分，在解决方案上，我目前采用的技术路线可以概括为四步。

首先是**数据集选取**，我选取了 Facebook、Twitter 和 TWeibo 三个典型社交网络数据集作为主要实验对象。

第二步是**基线方法选择**，我引入了 UGC，这是一种免训练、轻量级的通用图粗化方法，把它作为当前阶段的核心基线。

第三步是**数据分析**，对标准数据集和社交网络数据集的图结构、标签形式和特征维度进行分析，识别后续适配时可能遇到的问题。

第四步是**适配评估**，在完成算法复现之后，尝试把 UGC 应用于社交网络数据，并观察它在真实社交图上的表现。

3

接下来是前期结果验证部分

在前期实验中，我主要遇到了三类问题。对这三类问题，我也进行了一个临时基本的解决：

- 第一是**标签形态不兼容**。方法原本使用的数据集都是单标签，而这几个社交网络数据集都是多标签的。这会导致难以计算UGC算法的核心异质性因子 α 。

对这个问题，我采取了只保留节点首个标签的策略，但这会导致标签信息丢失。后续我可能考虑一些其它方法，比如选取主标签，使用线性层融合标签，甚至重新考虑 α 的计算方法。

- 第二是社交网络数据集**特征维度高、数据规模大**，UGC 方法需要进行特征矩阵与结构邻接矩阵的拼接，这就导致出现内存不足的问题。

这个问题在twitter和weibo数据集上都有出现，但facebook数据集较小，所以暂时只对这个数据集进行了实验验证。

- 第三是**社交网络中存在有向图**，这会打破 UGC 对对称拉普拉斯矩阵的前提假设。

对于这个问题，事实上UGC的代码并非完全不支持有向图，只是有向图可能不符合论文中的前提假设，后面我计划对比有向图和对称化之后的效果，选取一个效果更好的方法。

这里是我得到的一些实验结果：

一方面，我对**UGC 方法进行了复现**。在 Cora 和 Citeseer 这两个标准数据集上，我得到的结果与论文报告结果高度一致，这说明当前代码实现是正确且可行的，也为后续迁移到社交网络数据集打下了基础。

第二，我在 **Facebook 数据集** 上做了 α 的梯度测试。结果表明，随着 α 增大，模型的平均准确率整体上升，但与此同时压缩率会逐渐下降，也就是说，分类性能和压缩强度之间存在一个权衡关系。从当前实验结果来看， **α 在 0.5 到 0.6 区间时表现相对较好**，说明这一参数范围在当前设置下能够在准确率和压缩效果之间取得较优平衡。

4

接下来我的工作主要分为三个阶段。

第一阶段，大约一周，重点解决**内存瓶颈问题**，尝试通过特征降维、分块处理等方式，尽快跑通 Twitter 和 TWeibo 这类更大规模数据集。

第二阶段，大约两周，系统比较**多标签处理策略**和参数设置对结果的影响，对 UGC 在社交网络中的适配方式进行进一步优化。

第三阶段，同样大约两周，完成实验结果整理、图表绘制以及论文主体撰写，并同步准备后续答辩材料。

我的汇报到这里结束。

感谢各位老师聆听，恳请批评指正