

各位老师好，我是信息安全专业的石家伊。

我的毕业论文题目是《**基于图粗化的社交网络分析系统的设计与实现**》，指导老师是温延龙教授。

我的汇报分为四个部分，首先介绍本文的研究背景和主要工作；然后说明我对基线方法做的两方面优化；接着介绍系统的设计和实现；最后进行总结与展望。

1

首先是研究背景和主要工作部分。

本文的研究背景，是社交网络规模快速增长的当下，主要有两个现存问题。

- 第一是**数据规模巨大**。社交网络的节点数、边数和特征维度都很高，会带来较大的内存、显存和计算压力。
- 第二是**结构刻画困难**。现代社交图谱多维特征复杂，传统模型或简单抽样难以完整捕捉节点间深层关联。

因此，一种解决思路是引入**图粗化技术**，把相似节点聚合成超节点，构造一个规模更小的粗图，在降低计算复杂度的同时保留关键信息。

围绕这个目标，本文主要完成了四方面工作。

- 第一是对原始方法进行改进：
 - 提出相似度加权聚合方法，提升超节点特征表达能力
 - 并设计四种多标签处理策略，以适应多标签社交网络数据集。
 - 第二是补充了**平均标签纯度**和**低纯度超节点占比**两个指标，从超节点内部标签一致性的角度补充评价方法。
 - 第三，是在多个真实社交网络数据集上进行了对比实验，验证了改进方法的有效性
 - 第四，是设计并实现了一个基于 B/S 架构的图粗化分析系统，打通从数据上传到结果分析的全流程。
-

2

下面进入方法优化部分

首先，简单介绍一下原始 UGC 方法。

他首先将节点的特征向量与邻接向量拼接融合，形成一个更全面的节点表示。

之后采用局部敏感哈希 LSH，将相似节点聚合到同一个“哈希桶”中。

然后同一个桶内节点聚合为“超节点”，其特征与标签分别通过平均和投票方式产生。

最后，基于超节点内部原始节点的之间连接关系，构建粗图的超边并计算边权。

对原始方法，我一共做了两方面的改进。

一方面，UGC在生成超节点特征时采用的是平均聚合，这可能导致核心节点的特征被稀释，而噪声节点的影响被放大，从而降低后续 GNN 分类效果。

针对这个问题，我提出了**相似度加权聚合方案**。

先计算一个超节点内部所有成员节点的特征均值，然后再计算每个成员节点和这个原型之间的余弦相似度。相似度越高，说明这个节点越具有代表性，应该获得更大的权重。

之后，用 Softmax 把相似度转化成归一化权重，最后根据这些权重对节点特征进行加权求和。

另一方面的改进是针对多标签数据集，UGC方法原本不支持多标签数据集，所以我设计了四种多标签处理策略。

- 第一是**第一标签策略**。
它只取每个节点的第一个标签作为代表。这个方法实现简单，但缺点也很明显，就是会丢失大量标签信息。
 - 第二是**标签交集策略**。
只要两个节点的标签集合中交集，就认为它们是同类。这个方法利用了多标签信息，但条件过于宽松，容易导致类别塌缩问题。
 - 第三是**位置匹配策略**。
它要求两个节点在相同位置上出现相同标签，才认为它们同类。这个方法比 V2 更严格，但是过度依赖标签输入顺序，效果不一定可靠。
 - 第四种是**Jaccard 阈值策略**
它计算两个节点标签集合之间的 Jaccard 相似度，只有当相似度超过设定阈值时，才认为两个节点属于同类。总体来看，该策略在标签信息利用和类别区分度保持之间取得了比较好的平衡，效果最好。
-

接下来展示部分实验结果。

对于第一个优化，我分别在 50%、70% 压缩率下进行实验，其中，高压压缩率下的提升效果更好。

从结果可以看出，在 70% 这种更高压缩率下，加权聚合方法的优势更加明显，在 3 个社交网络数据集中均实现提升，说明该方法在高压压缩率场景下更具优势。

对于第二个优化，这里以 Facebook 数据集为例。可以看到，V1 因为丢失了大量标签信息，准确率最低。V2 出现了严重的类别塌缩问题，分类任务已经失去了意义。

相比之下，V4 能够在分类准确率和类别数保持之间取得更好的平衡。

3

下面介绍系统设计与实现部分。

系统采用的是 B/S 架构，整体分为四层。

- **用户交互层**。主要提供 Web 页面，支持数据上传、参数配置等可视化交互。
- **业务处理层**。基于 Flask 框架实现，主要负责前端请求解析、后台任务调度等，并维护系统运行状态。
- **算法计算层**。是系统的核心层，采用 Python 语言和 PyTorch 库，实现图粗化的全流程以及 GNN 分类测试。

- **数据存储层。**采用混合存储架构。数据库主要管理系统元数据，文件系统则负责存储大规模原始数据、日志文件等。
-

我录制了一个系统展示视频，请各位观看。

4

最后是总结与展望部分。

论文基于 UGC 方法进行优化与系统实现；提出相似度加权特征聚合和多标签处理策略，补充标签纯度评价指标，并通过真实数据集实验验证了方法有效性与系统可用性。

后续工作主要有两个方向。

第一是**特征矩阵优化**。面向高维特征和大规模社交网络数据，可引入特征矩阵稀疏化、特征选择和分块计算机制，降低特征矩阵与邻接矩阵拼接带来的内存开销。

第二是**模型与任务扩展**。后续可以接入更多 GNN 模型和图学习任务，拓展系统在社区发现、链路预测、用户分群等场景中的应用能力。

我的汇报到此结束。感谢各位老师的观看，恳请各位老师批评指正。